Gemini

# EVOLUCIÓN

Bard

PaLM 2

Gemini

# CONSTRUCCIÓN

## Multimodalidad Nativa

Capacidad de procesar en su modalidad nativa:
Imágenes → Píxeles
Audios → Ondas

## MoE

Mixture of Experts
Activa subredes neuronales con la relevancia como criterio.

# ARQUITECTURA

## Model Size

- **ULTRA** — Rendimiento de vanguardia en una amplia gama de tareas altamente complejas
- **PRO** — Un modelo optimizado en rendimiento, tanto en términos de costo como de latencia.
- **NANO** — El modelo más eficiente, diseñado para ejecutarse en el dispositivo.

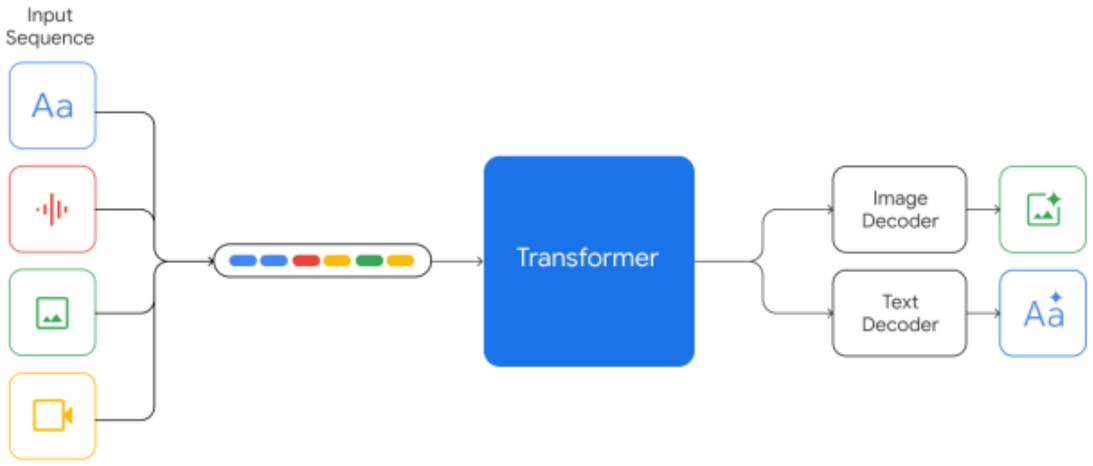

# ENTRENAMIENTO

## Training

Aceleradores TPU v4 y TPU v5e

## Evaluación

MMLU como Benchmark en sus diversos modales

1 — 2 — 3 — 4

## Pre-training

- Usa SentencePiece tokenizer
- Pretraining de Dataset

## Post-Training

- Recopilación de Datos de Prompt
- SFT sobre datos de demostración
- Training de RM sobre datos de retroalimentación
- RLHF

# FORTALEZAS

- Mayor capacidad de refinamiento (44.5%), indicando únicamente qué elementos requieren revisión, pero no especificamos cómo revisarlos.
- Capacidad de procesamiento mayor de 10 millones de tokens (400K GPT5.2-Medium, 200K Claude-4.5-Opus)

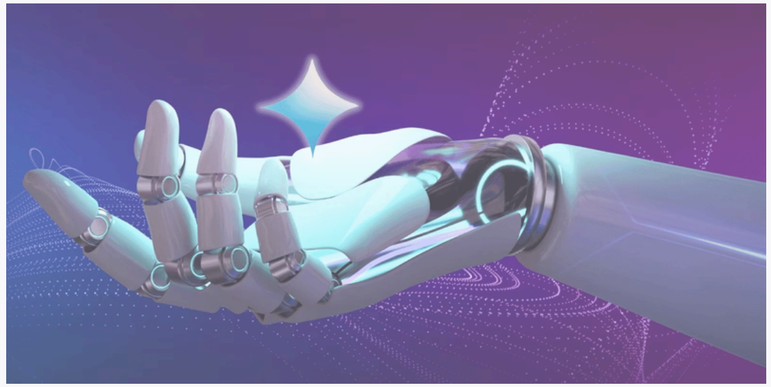

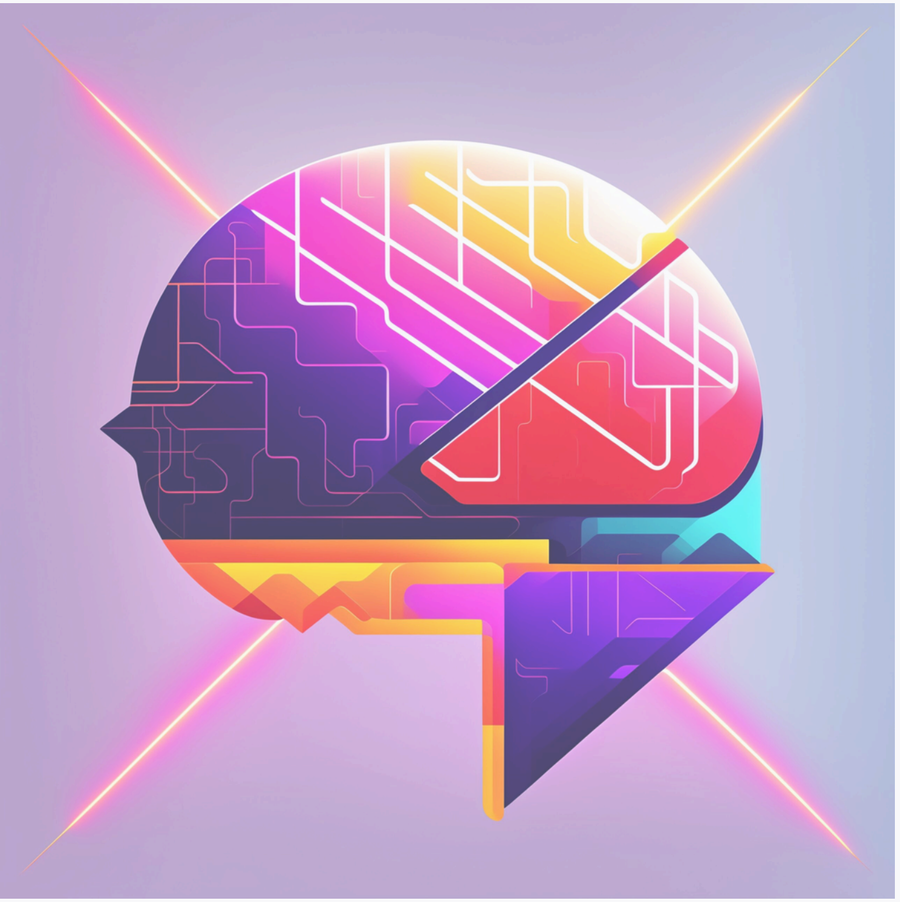

# LIMITACIONES

- Falta de autonomía crítica, dificultad para evaluar su propio trabajo.
- Operaciones aritméticas con varios dígitos, respecto a otros modelos.
- Utilizando LOCA-bench, observamos que la mayoría de los modelos, incluidos los de vanguardia y de código abierto, sufren una marcada caída en el rendimiento a medida que aumenta la longitud del contexto, y la brecha entre ellos se amplía en contextos más largos.

# *Gracias*

Deivy Paredes - Daniels Tinoco